租房数据分析

2020211376 马天成

0. 实验概述

0.1 题目要求

1. 抓取链家官网北上广深 4 个一线城市，再加上一个离你家乡最近的一个非一 线城市/或者你最感兴趣的一个城市的数据。应获取每个城市的全部租房数 据（一线城市的数据量应该在万的数量级）。
2. 比较 5 个城市的总体房租情况，包含租金的均价、最高价、最低价、中位数等信息，单位面积租金（元/平米）的均价、最高价、最低价、中位数等信息。 采用合适的图或表形式进行展示。
3. 比较 5 个城市一居、二居、三居的情况，包含均价、最高价、最低价、中位数等信息。
4. 计算和分析每个城市不同板块的均价情况，并采用合适的图或表形式进行展 示。 例如上图中的“海淀-四季青-五福玲珑居北区”，“四季青”即为板块名称。
5. 比较各个城市不同朝向的单位面积租金分布情况，采用合适的图或表形式进 行展示。哪个方向最高，哪个方向最低？各个城市是否一致？如果不一致， 你认为原因是什么？
6. 查询各个城市的人均 GDP，分析并展示其和单位面积租金分布的关系。相对 而言，在哪个城市租房的性价比最高？
7. 查询各个城市的平均工资，分析并展示其和单位面积租金分布的关系。相对 而言，在哪个城市租房的负担最重？
8. 围绕各城市租房问题，结合上述数据及分析，设计自己感兴趣的数据分析主 题，补充查找或爬取相关数据，完成题目设计、数据获取、数据分析及数据 展示过程。

0.2 报告要求

1. 实验报告中应包含爬虫核心代码、核心数据文件的基本结构、数据处理及数 据展示的核心代码。代码及文件中应包含足够的注释。
2. 报告应按照一般实验报告要求，至少包含明确的实验目的、过程、结论。
3. 报告以 pdf 格式提交，总页数不超过 30 页。
4. 报告具体提交方式由助教提供。
5. 报告提交截止时间：2022 年 12 月 31 日 24 点。

0.3 说明

1. 我选择 **合肥** 作为我的第五个城市。
2. 我收集了 **人均可支配收入**、**城市租房人数比率**、**城市非户籍常住人口比率** 来进行拓展分析
3. 由于报告30页限制，我将项目说明录制视频的连接放在这里，希望有所帮助：My Video
4. 我的 Github 仓库My Repositories (github.com)

1. 项目概述

下面是项目结构：

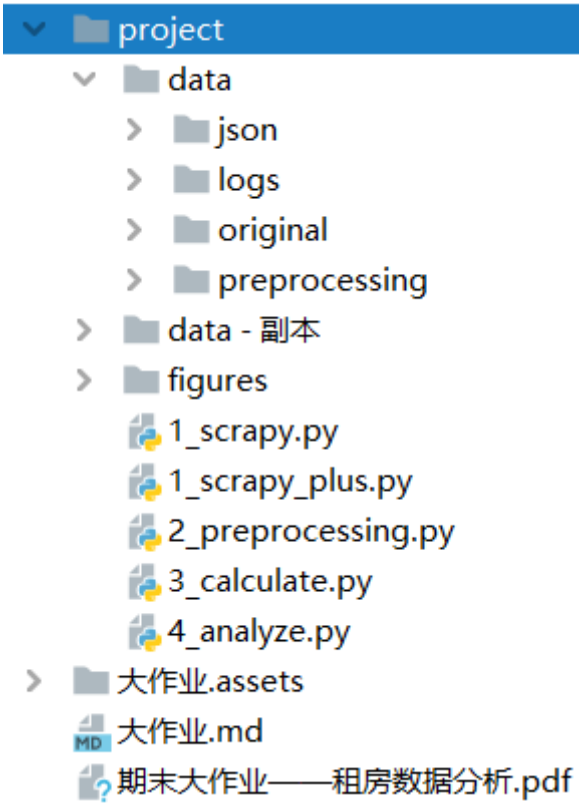

下面我将简单介绍一下各个文件：

1.1 Python代码部分（4个步骤）

这里有共有四个Python文件；这些文件的大致功能如下：

1. 数据爬取模块：输入爬取的 html，输出 csv 文件；plus 版是在分析完之后发现 **根据板块获取数据更好** 而做的改进版。
2. 数据预处理模块：输入 csv，输出 csv；将原先的 csv 文件进行 **去重** 和 **计算拓展成列**，生成新的有效 csv 文件，可供分析。
3. 数据计算模块：输入有效的 csv，输出 json；将 csv 的数据进行分析统计，算出**分析阶段需要并且可计算的所有数据**存入 json。
4. 分析模块：输入 json文件 和 查询数据；进行分析展示，存储图像并展示。

ATTENTION：所有的 Python 代码我都是经过：

1. 精心设计，反复修改；
2. 结构工整，思路清晰，无冗余代码；
3. 变量规范，常量定义完整；
4. 绝对不是 **shit mountain**！

1.2 data 文件夹（存储中间数据文件）

1.2.1 original 文件夹

存储了 **1_scrapy_plus.py** 中从网站爬下来的有效数据，根据城市区分，存储为 csv文件。

1.2.2 preprocessing & logs 文件夹

1. 在 **2_preprocessing.py** 进行预处理，中将上一个 original 文件夹中的数据进行 **去重**、**数据计算拓展**，生成可以直接进行第三部统计的 csv 文件。这个 csv 文件就存储在 **preprocessing 文件夹** 中。
2. 此外，在生成预处理数据数据时，我们会进行 **去重** 和 **删除非法记录**，在这个过程中，我们将：
    1. **记录及其重复次数 & 处理结果** 录入 **城市.log** 中
    2. **记录重复的详细信息** 录入 **城市_repeat.txt** 中
    3. **非法而删除的记录**录入 **城市_error.txt** 中
3. 在介绍预处理代码 - **2_preprocessing.py** 时我们会详细介绍这三个文件的格式和内容。

1.2.3 json 文件夹

1. 在 **3_calculate.py** 进行计算，中将上一个 preprocessing 文件夹中的数据进行 **计算**，生成城市的 json 文件，存储在 **json 文件夹** 。
2. 这些 json 文件计算了所有在分析阶段需要的数据。该计算已经将所有需要并可以计算的数据都计算出（一些在分析阶段引入的新数据需要重新计算），以字典形式存放为 json；此后就 **不再需要csv文件**， 只需要用 **json** 文件进行分析，大大减少数据量。

1.3 figure 文件夹

可算作分析结果。

存储了 **4_analyze.py** 的输出图像。

1.4 data - 副本 文件夹

存储了老版数据爬取方式（在城市主页用综合排序页面爬取）的数据。这个数据是比用城区爬取的数据差很多的。

2. 实验内容

2.1 数据爬取模块

1_scrapy_plus.py

```
from urllib.request import urlopen
```

```
from bs4 import BeautifulSoup
import csv

# target cities
cities = {'北京': 'bj', '上海': 'sh', '广州': 'gz', '深圳': 'sz', '合肥': 'hf'}

# csv outputFile attributes
csv_attributes = ['title', 'name', 'area', 'rooms', 'price_lower',
'price_upper']


# ***
records_in_a_page = 30

# get cities rent data
for name, info in cities.items():
    # root url path
    url_root = 'https://' + info + '.lianjia.com'

    # generate name.csv ------------------------------------------------------
    with open('data/original/'+name+".csv", 'w', newline='', encoding='utf-8-
sig') as outputFile:
        writer = csv.writer(outputFile)
        writer.writerow(csv_attributes)

        # 1, get districts path in this city ---------------------------------
        html = BeautifulSoup(urlopen(url_root + '/zufang'), features="lxml")
        # find all district blocks
        blocks = html.findAll(name='li', attrs={'class': 'filter__item--level2',
'data-type': 'district'})
        # get all district path (ignore the first district-'不限')
        district_path_list = list()
        for i in range(1, len(blocks)):
            district_path_list.append(blocks[i].find('a')['href'])

        # 2. get data each from each district pages --------------------------
        for path in district_path_list:
            # 2.1 get page size for this city from city's index page
            html = BeautifulSoup(urlopen(url_root + path), features="lxml")
            size_record = int(html.findAll(name="span", attrs={"class":
"content__title--hl"})[0].text)
            size_page = int(size_record / records_in_a_page)
            if( size_record % records_in_a_page > 0 ):
                size_page = size_page+1
            print(path, size_record, size_page)

            # 2.2 scrapy data in pages & copy data into file
            for i in range(1, size_page+1):
                print(i)
                html = BeautifulSoup(urlopen(url_root + path + 'pg' + str(i)),
features="lxml")

                # get data into list
                title_block = html.findAll("p", {"class": "content__list--item--
title"})
```

```
                des_block = html.findAll("p", {"class": "content__list--item--
des"})
                price_block = html.findAll("span", {"class": "content__list--
item-price"})
                for title, des, price in zip(title_block, des_block,
price_block):
                    # solve title
                    title = title.get_text().strip()
                    # solve des
                    des_list = des.get_text().split('/')
                    if len(des_list) == 5:
                        name = des_list[0].replace("\n","").strip()
                        area = des_list[1].replace("\n","").strip()[:-1]
                        rooms = des_list[3].replace("\n", "").strip()[0]
                    elif len(des_list) == 3:
                        name = ""
                        area = des_list[0].replace("\n", "").strip()[:-1]
                        rooms = des_list[2].replace("\n", "").strip()[0]
                    # solve price
                    text = price.get_text().split(' ')[0]
                    if '-' in text:
                        text = text.split('-')
                        price_lower = text[0]
                        price_upper = text[1]
                    else:
                        price_lower = text
                        price_upper = text
                    writer.writerows([[title, name, area, rooms, price_lower,
price_upper]])
```

这里不提供原版的代码了，在附录中会提供。

2.1.1 代码过程分析

1. 在开头给出五个城市的的 **命名和简写对照 dict**，方便自动遍历和爬取，用循环减少无谓的相似代码。
2. 再给出 csv 文件需要爬取的各个属性（属性行），以及一个页面的租房记录数：30。
3. 打开需要生成的文件：**data/original/城市名.csv**，并写入csv 的 属性行 csv_attributes
4. **循环**每个城市：
    1. 获取当前页面的 **地区标签相对 path**（藏于 href），存入 **district_list**。
    2. 根据 **district_list** 的元素到达每个子页面。获得当前的页面的租房数据数量，计算出该 district 遍历完所需的页面数：**记录数 / 单个页面记录数**（开头已给出定义）。然后**循环**进入每个该地区的顺序页面：
        1. 获取当前城市的html文件；
        2. 根据当前 html体，获取30个记录需要录入的数据，存为 list。循环该 list：
            1. 分析数据，将记录数据拆开，化成 attribute 的形式，一个个**写入 csv** 中。

2.1.2 数据转化细节分析

只需要在处理时取出相应数据，然后取出即可。下面有几个数据爬取策略

1. 几室：取出字段出去前导换行空格后的第一个字符。
2. 面积：删除前导后导空格换行，并删除最后一个字符。

2.2 数据预处理模块

2_preprocessing.py

```
import pandas as pd
import csv

# target cities
cities = {'北京': 'bj', '上海': 'sh', '广州': 'gz', '深圳': 'sz', '合肥': 'hf'}

# csv outputFile attributes
csv_attributes = ['title', 'name', 'area', 'rooms',
                  'price_lower', 'price_upper', 'price_average',
                  'price_square_lower', 'price_square_upper',
'price_square_average']


# preprocessing each city.csv with "deduplicate" and "append"
for name, info in cities.items():

    # read data & convert into list ------------------------------------------
    data = pd.read_csv('data/original/'+name+'.csv', encoding='utf-8-sig')
    data = data.values.tolist()
    original_size = len(data)
    print('preprocessing', name, original_size)

    # open log and error file
    logFile = open('data/logs/' + name + ".log", 'w', encoding='utf-8')
    repeatFile = open('data/logs/' + name + "_repeat.txt", 'w', encoding='utf-
8')
    errorFile = open('data/logs/' + name + "_error.txt", 'w', encoding='utf-8')

    # generate deduplicated data & write into file ----------------------------
    with open('data/preprocessing/' + name + ".csv", 'w', newline='',
encoding='utf-8-sig') as outputFile:
        writer = csv.writer(outputFile)
        writer.writerow(csv_attributes)

        # generate price_square_lower, price_square_upper & deduplicate
        i = 0
        cnt_delete = 0
        while i < len(data):
            # solve illegal records depend on rooms
            if str(data[i][3]).isdigit()==False or int(data[i][3])<=0:
                # write into error.log
                errorFile.write(str(data[i])+'\n')
```

```
                del data[i]
                cnt_delete += 1
                continue

            # deduplicate
            #print('deduplicate', i)
            cnt_repeat = 0
            j = i+1
            while j < len(data):
                # find repeat
                if data[i] == data[j]:
                    # write into repeat.log
                    repeatFile.write('['+str(i)+', '+str(j)+']
'+str(data[j])+'\n')
                    del data[j]
                    j -= 1
                    cnt_repeat += 1
                    cnt_delete += 1
                j += 1
            # for data[i], repeat cnt times
            if cnt_repeat > 0:
                logFile.write('repeat '+str(cnt_repeat)+' : '+str(data[i])+'\n')

            # append price_average, price_square_lower, price_square_upper,
price_square_average
            if '-' in str(data[i][2]):
                area = str(data[i][2]).split('-')
                area = (float(area[0]) + float(area[1])) / 2
            else:
                area = float(data[i][2])
            data[i].append((float(data[i][4]) + float(data[i][5])) / 2)
            data[i].append(float(data[i][4]) / area)
            data[i].append(float(data[i][5]) / area)
            data[i].append((float(data[i][7]) + float(data[i][8])) / 2)
            # has deduplicated this record with writing into csv
            writer.writerow(data[i])

            i += 1

        # write delete counts
        summary = 'delete(repeat&illegal) : '+str(cnt_delete)+' | orignal
'+str(original_size)+' remain '+str(len(data))
        logFile.write(summary)
        print(name, summary)

    # close log and error
    logFile.close()
    errorFile.close()
```

2.2.1 代码过程分析

1. 在开头给出五个城市的的 **命名和简写对照 dict**，方便自动遍历和爬取，用循环减少无谓的相似代码。
2. 再给出扩展后的 csv 文件需要爬取的各个属性（属性行）
3. 打开需要生成的文件：**data/preprocessing/城市名.csv**，并写入csv 的 属性行 csv_attributes
4. **循环**每个城市：
    1. 读取出这个城市的 original csv 文件并读出。
    2. 循环每一条记录：
        1. 当前记录不合法：**几室 - 录入了"未"字 || 数据为0**。删除该数据，放入 **error.txt** 中，continue。
        2. **计算该条数据需要拓展的列数据（属性）**
        3. 从下一条记录开始找到最后，**循环**到最后一条：
            1. 假如记录和循环外的重复，则记录为重复，放入 **repeat.txt** 中。
        4. 假如当前的记录找到了重复，则把该条记录和重复次数放入 **城市名.log** 中。
    3. 将原记录数，删除记录数，剩余记录数最后再放入 **城市名.log** 中。
    4. 将删除后的数据写入新的 csv 文件：**data/preprocessing/城市名.csv**

2.2.2 输出文件格式样式

城市.log

repeat.txt

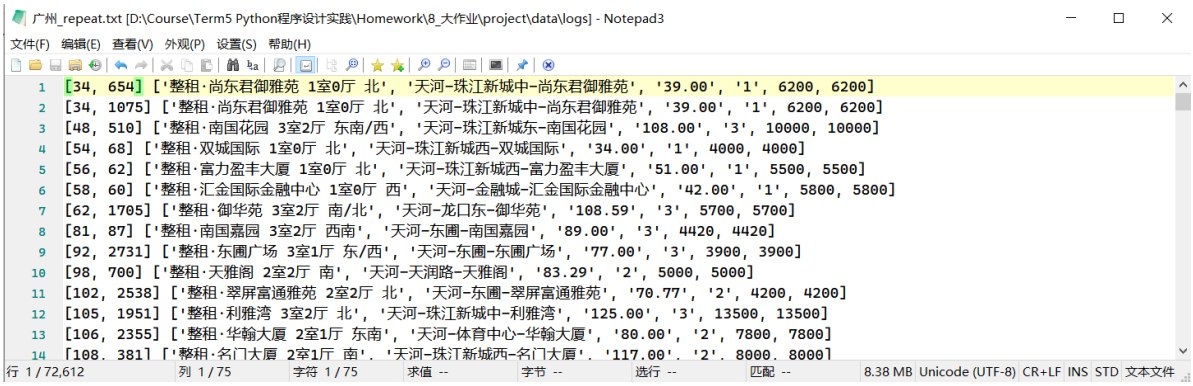

error.txt

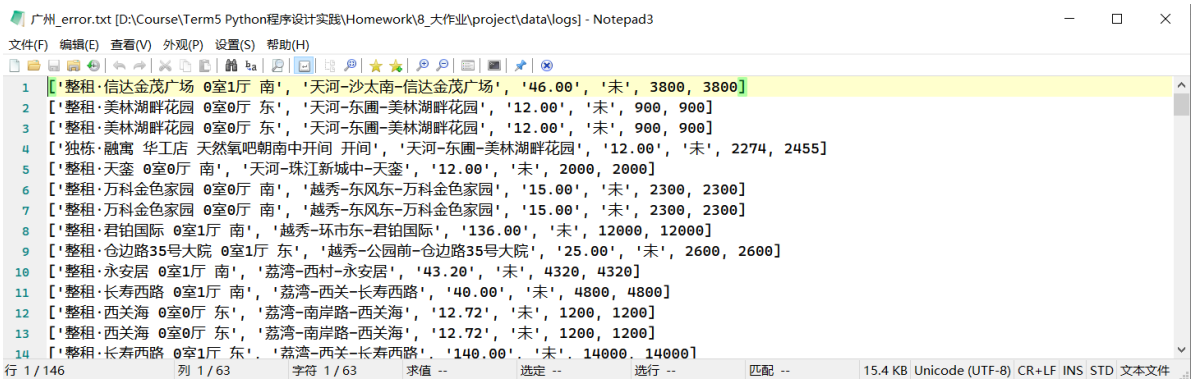

2.3 数据计算模块

3_calculate.py

```
import pandas as pd
import json

# target cities
cities = {'北京': 'bj', '上海': 'sh', '广州': 'gz', '深圳': 'sz', '合肥': 'hf'}

# csv outputFile attributes
csv_attributes = ['title', 'name', 'area', 'rooms',
                  'price_lower', 'price_upper', 'price_average',
                  'price_square_lower', 'price_square_upper',
'price_square_average']


# calculate each city.json
for name, info in cities.items():

    # read data & convert into list ---------------------------------------------
    data = pd.read_csv('data/preprocessing/'+name+'.csv')
    data = data.values.tolist()
    # preprocessing json list
    city_dict = dict()

    # generate city_json[0][1][2] (size & price & price_square) ---------------
    # variables
    price_total = 0
    price_lower = 0x3F3F3F
    price_upper = 0
    price_square_total = 0
    price_square_lower = 0x3F3F3F
    price_square_upper = 0

    # judge for each record
    for record in data:
        # update price-total, lower, upper
        price_total = price_total + float(record[6])
        price_lower = min(float(record[4]), price_lower)
        price_upper = max(float(record[5]), price_upper)
        # update price_square-total, lower, upper
```

```
            price_square_total = price_square_total + float(record[9])
            price_square_lower = min(float(record[7]), price_square_lower)
            price_square_upper = max(float(record[8]), price_square_upper)

        # calculate average and middle
        price_average = price_total / len(data)
        sorted(data, key=(lambda x: x[6]))  # sort by price_average
        index = int(len(data)/2)
        if len(data) & 1 == 1:
            price_middle = float(data[index][6])
        else:
            price_middle = (float(data[index][6]) + float(data[index+1][6])) / 2

        # calculate price_square average and middle for room_i
        price_square_average = price_square_total / len(data)
        sorted(data, key=(lambda x: x[9]))  # sort by price_square_average
        index = int(len(data)/2)
        if len(data) & 1 == 1:
            price_square_middle = float(data[index][9])
        else:
            price_square_middle = (float(data[index][9]) + float(data[index+1][9]))
/ 2

        # store calculate data into json
        city_dict['size'] = len(data)
        city_dict['price'] = {'average': price_average,
                              'lower': price_lower,
                              'upper': price_upper,
                              'middle': price_middle}
        city_dict['price_square'] = {'average': price_square_average,
                              'lower': price_square_lower,
                              'upper': price_square_upper,
                              'middle': price_square_middle}

        # generate city_json[3:5] (room1:3 calculate) ----------------------------
        # variables (list for room_1, room_2, room_3)
        rooms = [list(), list(), list()]
        price_total = [0, 0, 0]
        price_lower = [0x3F3F3F, 0x3F3F3F, 0x3F3F3F]
        price_upper = [0, 0, 0]
        # judge for each record
        for record in data:
            if record[3] <= 3:
                index = record[3]-1
                # store this record
                rooms[index].append(record)
                # update price-total, lower, upper
                price_total[index] = price_total[index] + float(record[6])
                price_lower[index] = min(float(record[4]), price_lower[index])
                price_upper[index] = max(float(record[5]), price_upper[index])

        # variables
        price_average = [0, 0, 0]
        price_middle = [0, 0, 0]
        for i in range(3):
```

```
        # calculate average and middle
        price_average[i] = price_total[i]/len(rooms[i])
        sorted(rooms[i], key=(lambda x: x[6]))  # sort by price_average
        index = int(len(rooms[i])/2)
        if len(rooms[i])&1 == 1:
            price_middle[i] = float(rooms[i][index][6])
        else:
            price_middle[i] = float(float(rooms[i][index][6])+float(rooms[i]
[index+1][6]))/2

        # store calculate data into city.json
        key = 'room_'+str(i+1)
        city_dict[key] = {'size': len(rooms[i]),
                          'average': price_average[i],
                          'lower': price_lower[i],
                          'upper': price_upper[i],
                          'middle': price_middle[i]}

    # generate city_json[6:9] (north & south & west & east) -------------------
    size = [0, 0, 0, 0]
    price_square_total = [0, 0, 0, 0]
    for record in data:
        if '北' in record[0]:
            size[0] += 1
            price_square_total[0] += float(record[9])
        if '南' in record[0]:
            size[1] += 1
            price_square_total[1] += float(record[9])
        if '西' in record[0]:
            size[2] += 1
            price_square_total[2] += float(record[9])
        if '东' in record[0]:
            size[3] += 1
            price_square_total[3] += float(record[9])

    # store calculate data into city.json
    city_dict['North'] = {'size': size[0], 'price_square_average':
price_square_total[0] / size[0]}
    city_dict['South'] = {'size': size[1], 'price_square_average':
price_square_total[1] / size[1]}
    city_dict['West'] = {'size': size[2], 'price_square_average':
price_square_total[2] / size[2]}
    city_dict['East'] = {'size': size[3], 'price_square_average':
price_square_total[3] / size[3]}

    # generate city_json[10] (plate) ------------------------------------------
    # store plates' name
    plate_set = set()
    for record in data:
        # cause some records has no plate!!!
        if type(record[1]) == str and record[1] != 'nan':
            plate_set.add(record[1].split('-')[1])

    # generate each plates' price_average
    plate_list = list(plate_set)
```

```
    plate_size = [0] * len(plate_list)
    plate_total = [0] * len(plate_list)
    for record in data:
        if type(record[1]) == str and record[1] != 'nan':
            index = plate_list.index(record[1].split('-')[1])
            plate_size[index] += 1
            plate_total[index] += record[6]
    plate_dict = dict()
    for i in range(len(plate_list)):
        plate_dict[plate_list[i]] = {'size': plate_size[i], 'average':
plate_total[i] / plate_size[i]}

    # store calculate data into city.json
    city_dict['plates'] = {'size': len(plate_list), 'data': plate_dict}

    # write city.json --------------------------------------------------------
    with open('data/json/' + name + ".json", 'w') as jsonFile:
        jsonFile.write(json.dumps(city_dict, indent=1, ensure_ascii=False))
```

2.3.1 代码过程分析

1. 在开头给出五个城市的的 **命名和简写对照 dict**，方便自动遍历和爬取，用循环减少无谓的相似代码。
2. 循环每个城市：
    1. 读入文件：**data/preprocessing/城市名.csv**
    2. 计算 **租房价格** 的：平均值，最小值，最大值，中位数。
    3. 计算 **单位面积租房价格** 的：平均值，最小值，最大值，中位数。
    4. 计算一室二室三室的 **租房价格** 的：平均值，最小值，最大值，中位数。
    5. 计算东南西北 **单位面积租房价格** 的：平均值，最小值，最大值，中位数。
    6. 计算出板块集合，循环每一个板块：
        1. 找到所有的板块，记录相应数据。
    7. 算出各个板块的 **平均单位面积租房价格。**
    8. 将上述数据存入 **data/json/城市.json** 中。

2.3.1 json 文件样例

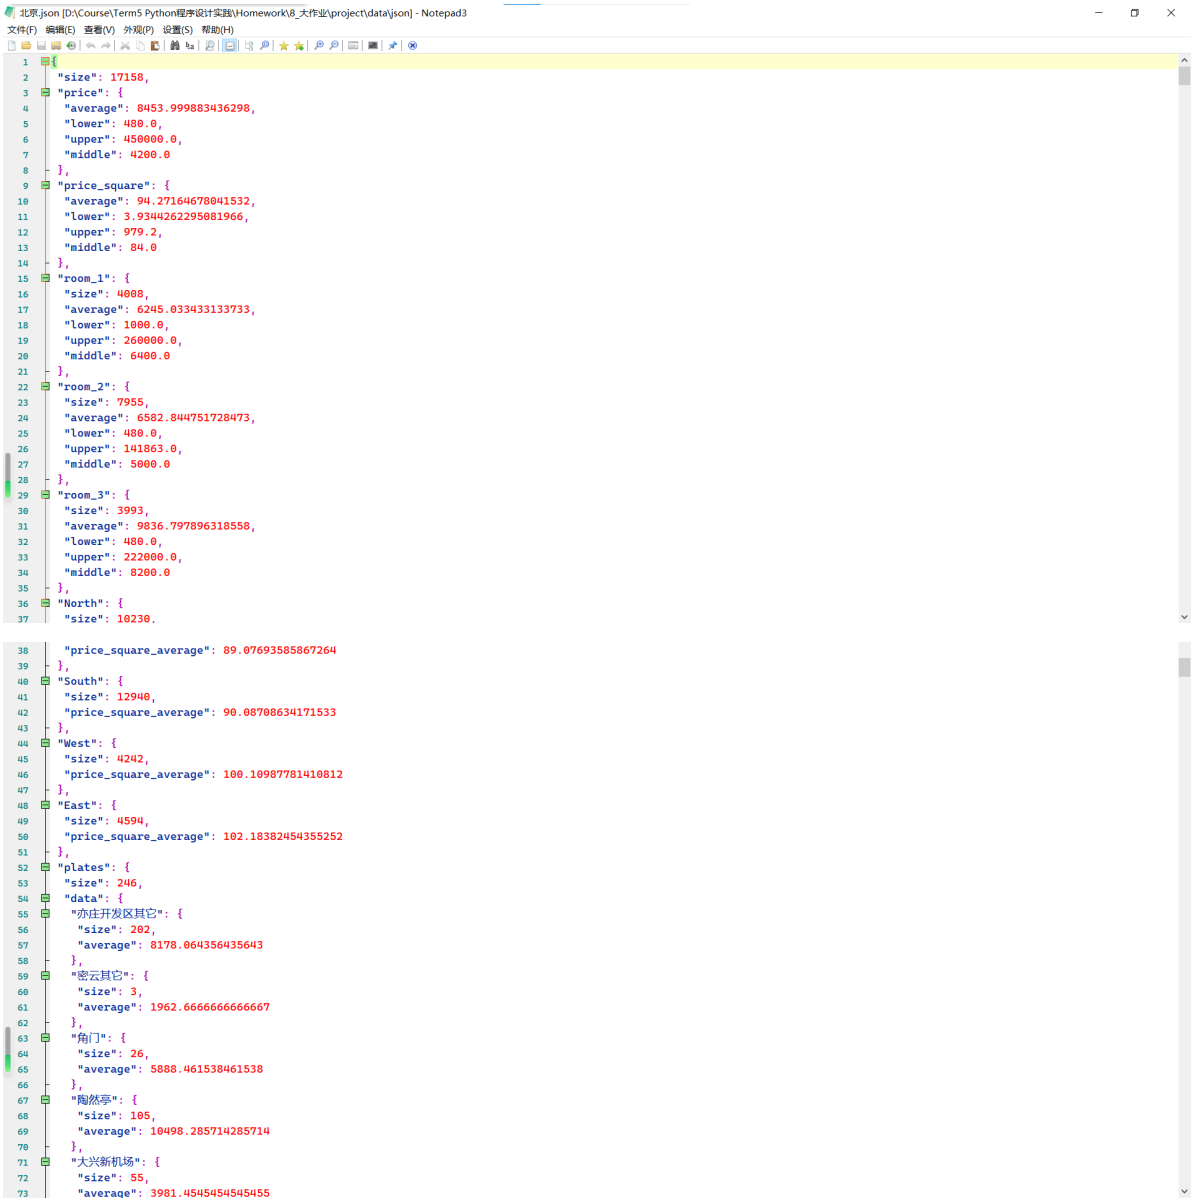

2.4 分析模块

4_analyze.py

```
import matplotlib.pyplot as plt
import json


# target cities
cities = {'北京': 'bj', '上海': 'sh', '广州': 'gz', '深圳': 'sz', '合肥': 'hf'}
city_name = ['北京', '上海', '广州', '深圳', '合肥']

# path
path_json = 'data/json/'
path_figure = 'figures/'
# figure count for saving
cnt_figure = 1


# read city.json data ------------------------------------------------------------
data_dict = dict()
```

```
for name in city_name:
    with open(path_json + name + '.json', 'r') as f:
        data_dict[name] = json.load(f)



# analyze preparations ------------------------------------------------------

# set each data size
city_size = 5
price_size = 4
room_size = 3
direction_size = 4

# set keys to find in data_dict
price_keys = ['average', 'lower', 'upper', 'middle']
room_keys = ['room_1', 'room_2', 'room_3']
direction_keys = ['North', 'South', 'West', 'East']

# set limits (has manually selected from json)
price_limit = 400000
price_square_limit = 3000

# set color list
color_city = ['orange', 'deepskyblue', 'orchid', 'g', 'y']
color_room = ['orange', 'deepskyblue', 'orchid', 'g']
color_direction = ['orange', 'deepskyblue', 'orchid', 'g']

# set pie label
pie_room = ['room_1', 'room_2', 'room_3', 'room_>=4']   # add last two show

# set font
plt.rcParams['font.sans-serif'] = ['SimHei']



# Task 1: compare 5 cities --------------------------------------------------

# 1.1: compare 5 cities with price

plt.figure(figsize=(40, 20))
# find each price category with i (generate 4 sub figures)
for i in range(price_size):
    # basic settings
    plt.subplot(1, price_size, i + 1)
    plt.title('Price-'+price_keys[i], fontsize=30)
    plt.xlabel('cities', fontsize=15)
    plt.ylabel('price(￥/m^2)', fontsize=15)

    # generate x & y data
    x = [i for i in range(1, city_size+1)]
    y = list()
    for name in city_name:
        y.append(data_dict[name]['price'][price_keys[i]])
```

```
    # generate subplot
    plt.ylim((0, price_limit))
    plt.bar(x, y, color=color_city)
    # add text
    plt.xticks(x, city_name, size=30)
    for x_value, y_value in zip(x, y):
        plt.text(x_value, y_value, '%.4f' % y_value, ha='center', fontsize=15)

# print & save plot
plt.suptitle('Price Compare',fontsize=30)
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()


# 1.2: compare 5 cities with price_average

plt.figure(figsize=(40, 20))
# find each price category with i (generate 4 sub figures)
for i in range(price_size):
    # basic settings
    plt.subplot(1, price_size, i + 1)
    plt.title('Price_square-'+price_keys[i], fontsize=30)
    plt.xlabel('cities', fontsize=15)
    plt.ylabel('price(￥/m^2)', fontsize=15)

    # generate x & y data
    x = [i for i in range(1, city_size+1)]
    y = list()
    for name in city_name:
        y.append(data_dict[name]['price_square'][price_keys[i]])

    # generate subplot
    plt.ylim((0, price_square_limit))
    plt.bar(x, y, color=color_city)
    # add text
    plt.xticks(x, city_name, size=30)
    for x_value, y_value in zip(x, y):
        plt.text(x_value,y_value,'%.4f'%y_value, ha='center', fontsize=15)

# print & save plot
plt.suptitle('Price Square Compare',fontsize=30)
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()



# Task 2: compare each cities' room1,2,3 -------------------------------------

# 2.1: self compare rate

plt.figure(figsize=(40, 20))
# find each city with i (generate 5 sub figures)
for i in range(city_size):
```

```
    # basic settings
    plt.subplot(1, city_size, i + 1)
    plt.title(city_name[i], fontsize=100)

    # generate room1, 2, 3, >=4 sizes
    sizes = list()
    for j in range(room_size):
        sizes.append(100 * data_dict[city_name[i]][room_keys[j]]['size'] /
data_dict[city_name[i]]['size'])
    # generate the rest size for >=4
    total_123 = 0
    for item in sizes:
        total_123 += item
    sizes.append(100-total_123)

    # generate subplot with text
    patches, l_text, p_text = \
        plt.pie(sizes, labels=pie_room, colors=color_room, autopct='%1.1f%%',
startangle=90)
    plt.axis('equal')
    # adjust words size
    for item in p_text:
        item.set_size(20)

# print & save plot
plt.suptitle('Rooms Components',fontsize=30)
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()


# 2.2: compare room1, 2, 3 between cities depend on price

# find room_1, 2, 3 with i (generate 3 figures)
for i in range(room_size):
    plt.figure(figsize=(40, 20))

    # find price category with i (generate 4 sub figures)
    for j in range(price_size):
        # basic settings
        plt.subplot(1, price_size, j + 1)
        plt.title('Price-' + price_keys[j], fontsize=30)
        plt.xlabel('cities', fontsize=15)
        plt.ylabel('price(￥/m^2)', fontsize=15)

        # generate x & y data
        x = [i for i in range(1, city_size+1)]
        y = list()
        # find each city - room_i+1 - price_key - price number
        for name in city_name:
            y.append(data_dict[name][room_keys[i]][price_keys[j]])

        # generate subplot
        plt.bar(x, y, color=color_city)
        # add text
```

```
        plt.xticks(x, city_name, size=15)
        for x_value, y_value in zip(x, y):
            plt.text(x_value, y_value, '%.4f' % y_value, ha='center',
fontsize=15)

    # print & save plot
    plt.suptitle(room_keys[i]+' Compare (no limit to flush y)', fontsize=30)
    plt.savefig(path_figure + str(cnt_figure))
    cnt_figure += 1
    plt.show()



# Task 3: compare each cities' plates ----------------------------------------

# compare each city's plates (generate 5 figures)
for name in city_name:
    plt.figure(figsize=(40, 20))
    # basic settings
    plt.title(name+' plates average price', fontsize=30)
    plt.xlabel('plates', fontsize=15)
    plt.ylabel('price(￥/m^2)', fontsize=15)

    # select plates witch has big size(top 10 percent)
    temp = data_dict[name]['plates']['data']    # get all plates' information
    # store each plates tuple(name, size)
    temp_list = list()
    for info_name, info_data in temp.items():
        temp_list.append([info_name, info_data['size']])
    sorted(temp_list, key=(lambda x: x[1]), reverse=True)

    # generate x data
    x_size = int(data_dict[name]['plates']['size'] / 10)
    x = [i for i in range(1, x_size+1)]

    # generate x label and y data
    x_name = list()
    y = list()
    for i in range(x_size):
        info_name = temp_list[i][0]
        x_name.append(info_name)
        y.append(data_dict[name]['plates']['data'][info_name]['average'])

    # generate subplot
    plt.bar(x, y, color=color_city)
    # add text
    plt.xticks(x, x_name, size=30)
    for x_value, y_value in zip(x, y):
        plt.text(x_value, y_value, '%.4f' % y_value, ha='center', fontsize=15)

    # print & save plot
    plt.savefig(path_figure + str(cnt_figure))
    cnt_figure += 1
    plt.show()
```

```
# Task 4: compare each cities' directions -----------------------------------

# compare each city's plates (generate 5 figures)
plt.figure(figsize=(40, 20))
for i in range(city_size):
    # basic settings
    plt.subplot(1, city_size, i+1)
    plt.title(city_name[i]+' directions\naverage square price', fontsize=30)
    plt.xlabel('direction', fontsize=15)
    plt.ylabel('price(￥/m^2)', fontsize=15)

    # generate x data
    x = [i for i in range(1, direction_size+1)]

    # generate y data
    y = list()
    for info in direction_keys:
        y.append(data_dict[city_name[i]][info]['price_square_average'])

    # generate subplot
    plt.bar(x, y, color=color_direction)
    # add text
    plt.xticks(x, direction_keys, size=30)
    for x_value, y_value in zip(x, y):
        plt.text(x_value, y_value, '%.4f' % y_value, ha='center', fontsize=15)

# print & save plot
plt.suptitle('Direction Compare (no limit to flush y)', fontsize=30)
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()



# Task 5: compare each cities' GDP & price_square ----------------------------

GDP = {'北京': 183980, '上海': 173630, '广州': 151200, '深圳': 174600, '合肥':
121800}

'''ATTENTION:
    we suppose that each person need rent a room with 20m^2
    such we induct a rate to represent:
        20m^2 room price / GDP
'''

# generate this rate
square = 20
months = 12
rates = list()
for name, number in GDP.items():
    rates.append(months * square * data_dict[name]['price_square']['average'] /
number)

# basic settings
```

```
plt.figure(figsize=(40, 20))
plt.title('Compare GDP & price_square\n with rate: 20m^2 room price / GDP',
fontsize=30)
plt.xlabel('cities', fontsize=30)
plt.ylabel('rate(1)', fontsize=30)

# generate x & y data
x = [i for i in range(1, city_size+1)]
y = rates

# generate subplot
plt.bar(x, y, color=color_city)
# add text
plt.xticks(x, city_name, size=30)
for x_value, y_value in zip(x, y):
    plt.text(x_value, y_value, '%.4f' % y_value, ha='center', fontsize=30)

# print & save plot
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()



# Task 6: compare each cities' Income & price_square --------------------------

Income = {'北京': 127535, '上海': 136752, '广州': 118133, '深圳': 153471, '合肥':
104729}

'''ATTENTION:
    we suppose that each person need rent a room with 20m^2
    such we induct a rate to represent:
        20m^2 room price / Income
'''

# generate this rate
square = 20
months = 12
rates = list()
for name, number in Income.items():
    rates.append(months * square * data_dict[name]['price_square']['average'] /
number)

# basic settings
plt.figure(figsize=(40, 20))
plt.title('Compare Income & price_square\n with rate: 20m^2 room price /
Income', fontsize=30)
plt.xlabel('cities', fontsize=30)
plt.ylabel('rate(1)', fontsize=30)

# generate x & y data
x = [i for i in range(1, city_size+1)]
y = rates

# generate subplot
```

```
plt.bar(x, y, color=color_city)
# add text
plt.xticks(x, city_name, size=30)
for x_value, y_value in zip(x, y):
    plt.text(x_value, y_value, '%.4f' % y_value, ha='center', fontsize=30)

# print & save plot
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()



# Task 7: further analyze ----------------------------------------------------

# 人均可支配收入（税后）
Income_Discretionary = {'北京': 75002, '上海': 78027, '广州': 74416, '深圳': 70847,
'合肥': 46009}

big_city_name = ['北京', '上海', '广州', '深圳']
# 租房人数比例（未查询到合肥）
Rate_rent = {'北京': 0.333, '上海': 0.384, '广州': 0.508, '深圳': 0.768}
# 非本地户籍人口比例
Rate_inward = {'北京': 0.385, '上海': 0.421, '广州': 0.489, '深圳': 0.665}


# Q1: Continue GDP and Income, how about Income_Discretionary? ---------------

'''ATTENTION:
    we suppose that each person need rent a room with 20m^2
    such we induct a rate to represent:
        20m^2 room price / Income_Discretionary
'''

# generate this rate
square = 20
months = 12
rates = list()
for name, number in Income_Discretionary.items():
    rates.append(months * square * data_dict[name]['price_square']['average'] /
number)

# basic settings
plt.figure(figsize=(40, 20))
plt.title('Compare Income & price_square\n with rate: 20m^2 room price /
Income_Discretionary', fontsize=30)
plt.xlabel('cities', fontsize=30)
plt.ylabel('rate(1)', fontsize=30)

# generate x & y data
x = [i for i in range(1, city_size+1)]
y = rates

# generate subplot
plt.bar(x, y, color=color_city)
```

```
# add text
plt.xticks(x, city_name, size=30)
for x_value, y_value in zip(x, y):
    plt.text(x_value, y_value, '%.4f' % y_value, ha='center', fontsize=30)

# print & save plot
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()


# Q2: How about Rate_rent and Rate_inward? ----------------------------------

'''ATTENTION:
    we suppose that each person need rent a room with 20m^2
    such we induct a rate to represent:
        20m^2 room price / Income_Discretionary
'''

# generate this rate: rent in inward
rent_in_inward = list()
for s, t in zip(Rate_rent.values(), Rate_inward.values()):
    rent_in_inward.append(s/t)

# basic settings
plt.figure(figsize=(40, 20))
plt.title('Rate_rent / Rate_inward', fontsize=30)
plt.xlabel('cities', fontsize=30)
plt.ylabel('rate(1)', fontsize=30)

# generate x & y data
x = [i for i in range(1, len(rent_in_inward)+1)]
y = rent_in_inward

# generate subplot
plt.bar(x, y, color=color_city)
# add text
plt.xticks(x, big_city_name, size=30)
for x_value, y_value in zip(x, y):
    plt.text(x_value, y_value, '%.4f' % y_value, ha='center', fontsize=30)

# print & save plot
plt.savefig(path_figure + str(cnt_figure))
cnt_figure += 1
plt.show()
```

过程这里就不详细分析了，其实就是根据 json 画图。在下一个实验结果分析中详细阐述。

3. 实验结果分析

Q1：比较 5 个城市的总体房租情况

价格：

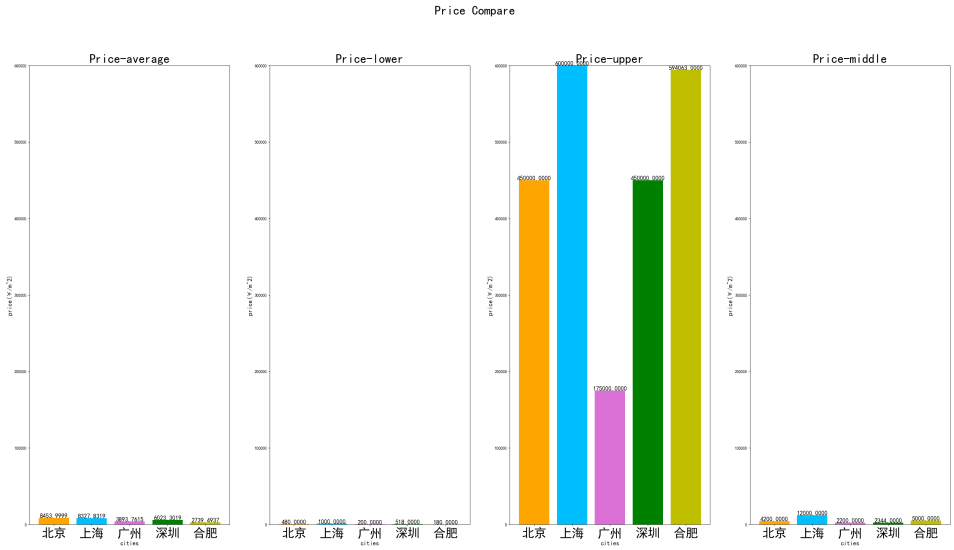

单位面积价格：

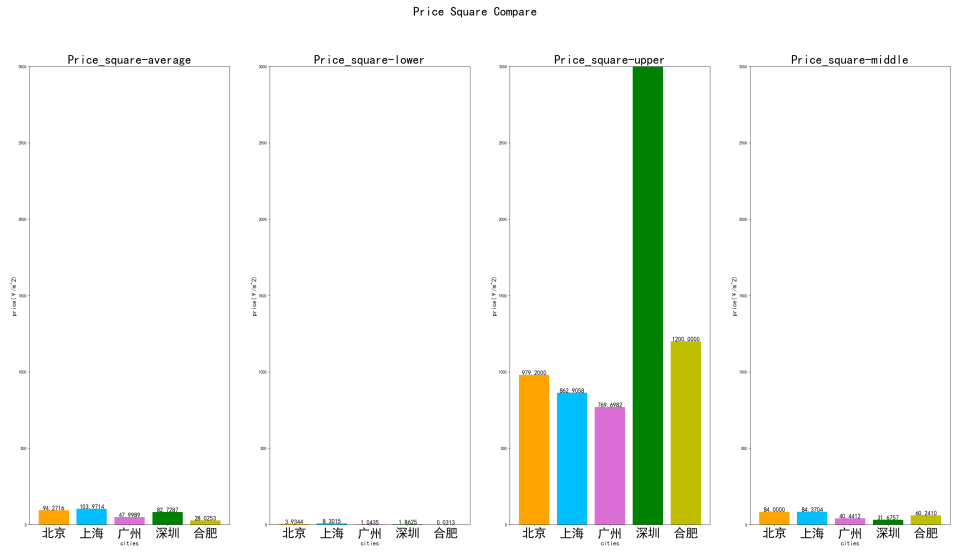

主要比较北京上海：

1. 北京平均价格偏高但中位数价格低很多：上海住房价格较为集中，北京有更多高房价租房。
2. 单位面积上海比北京高，上海住房面积小。

Q2：比较 5 个城市一居、二居、三居的情况

各个占比：

Rooms Components

北京　　上海　　广州　　深圳　　合肥

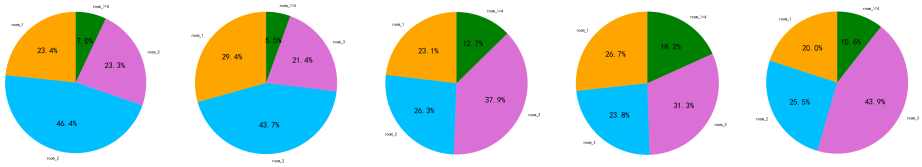

一室价格:

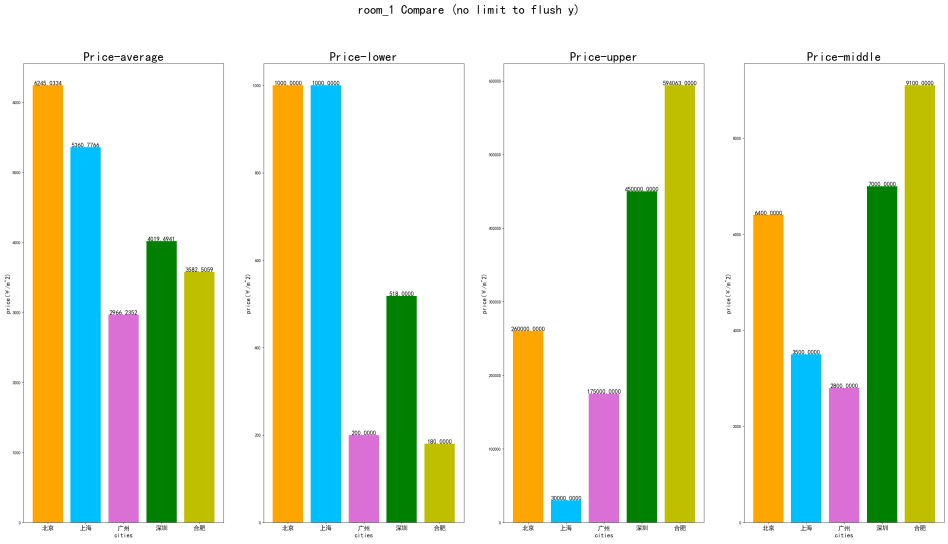

二室价格:

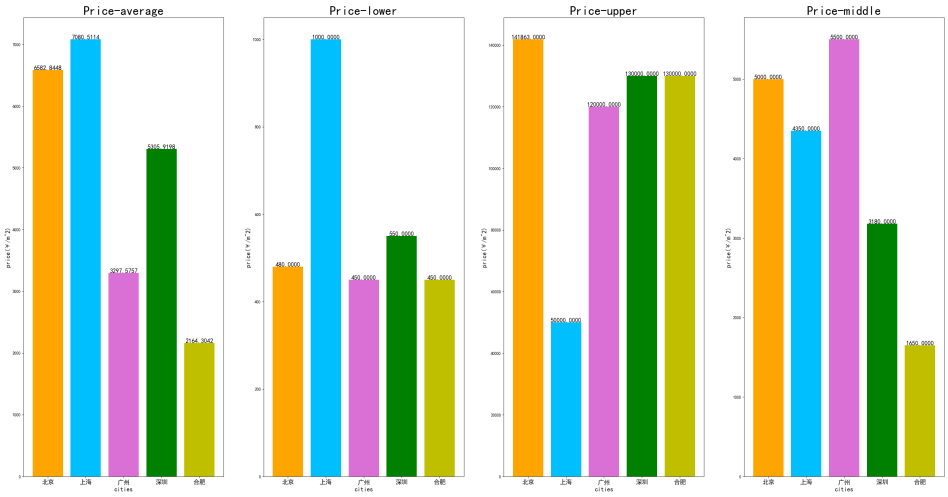

三室价格:

1. 北京一室很贵，上海二室三室很贵
2. 合肥一室很贵，广州二室三室很贵，深圳比他俩都高但比上海北京低。

Q3：计算和分析每个城市不同板块的均价情况

ATTENTION：由于板块数量巨多，我们只选取前 **10%** 展示

北京：

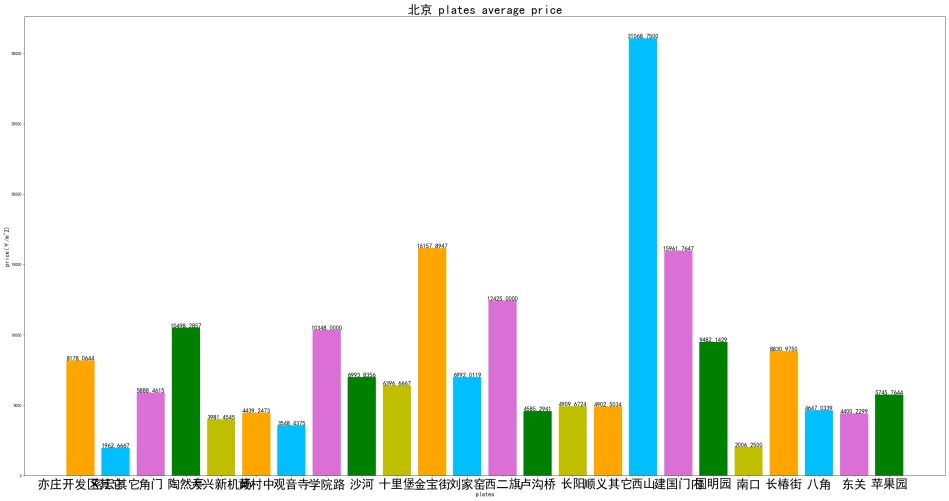

上海：

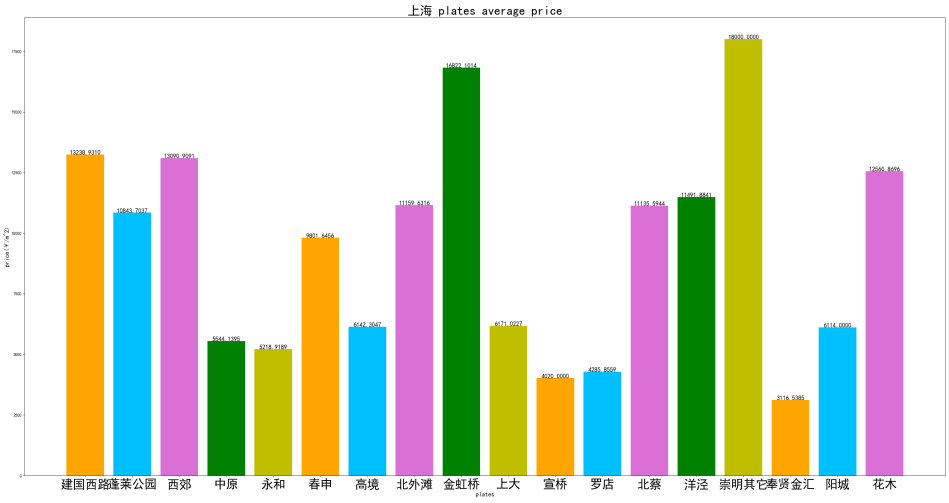

广州：

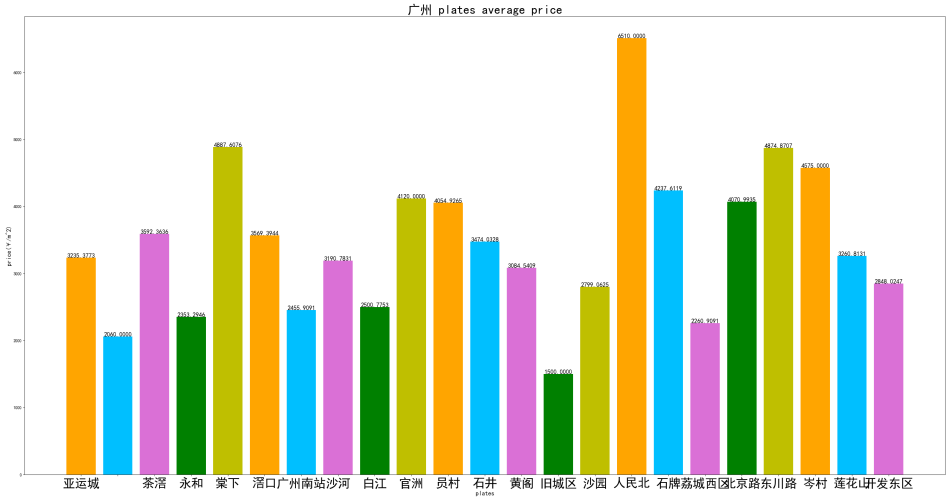

深圳：

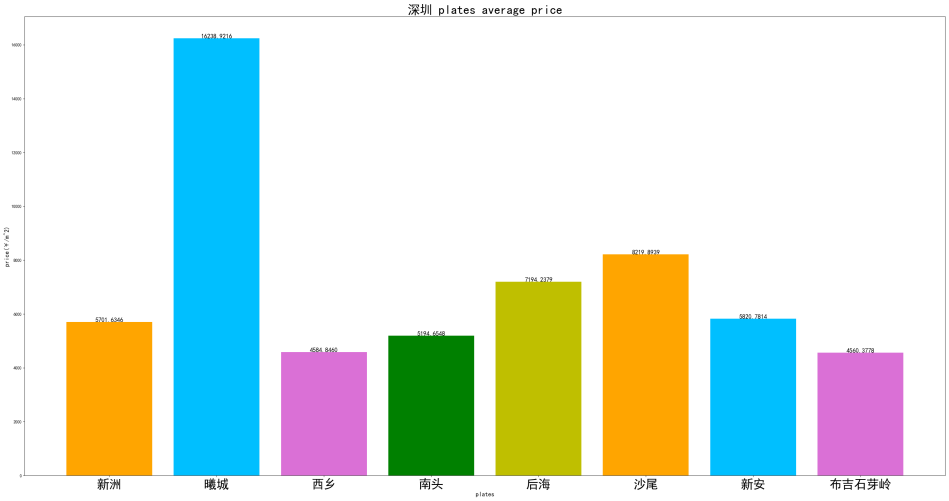

合肥：

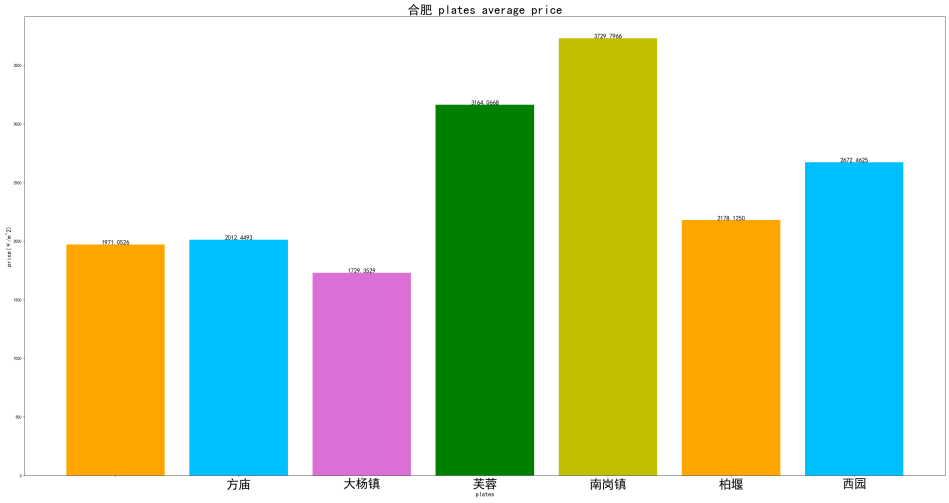

Q4：比较各个城市不同朝向的单位面积租金分布情况

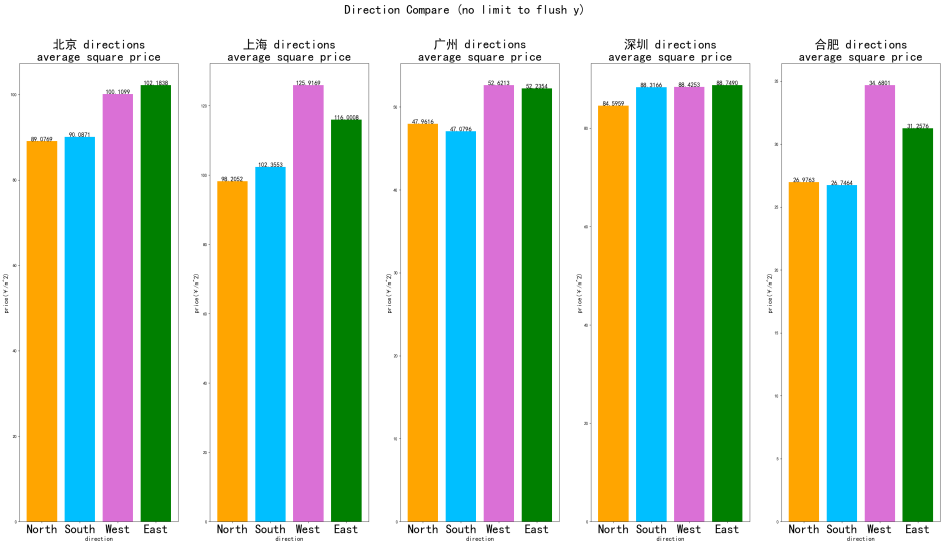

1. 各个城市不一致，比如深圳居然西边价格明显贵一点。
2. 东西朝向的房屋价格普遍比南北朝向贵（一个小前提）。
3. 沿海城市更看重南北朝向。
4. 大体上还是东南贵一点。

Q5： GDP & 单位面积租金分布

ATTENTION：我们引入变量：20平方米一年所支付的租金占总金额数值的比例

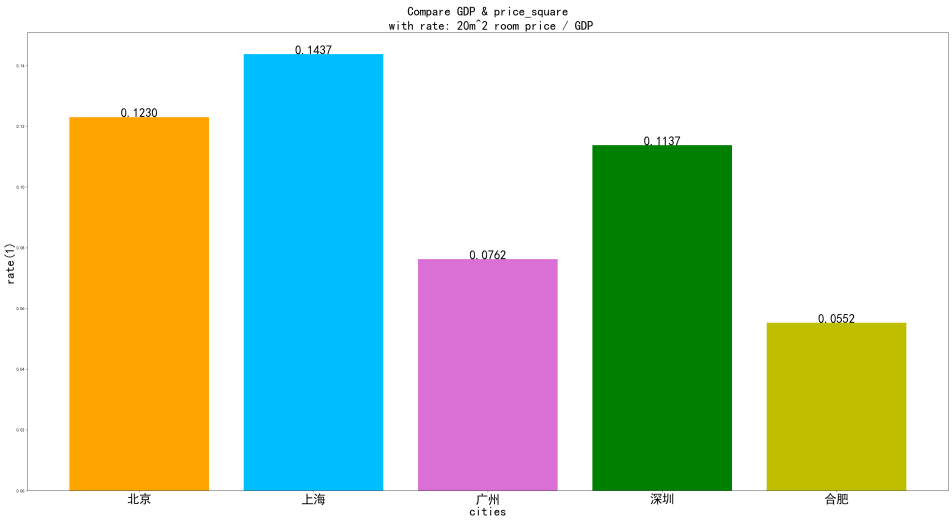

可以看到上海最贵，北京和深圳差不多，合肥最低。

Q6： 平均工资 & 单位面积租金分布

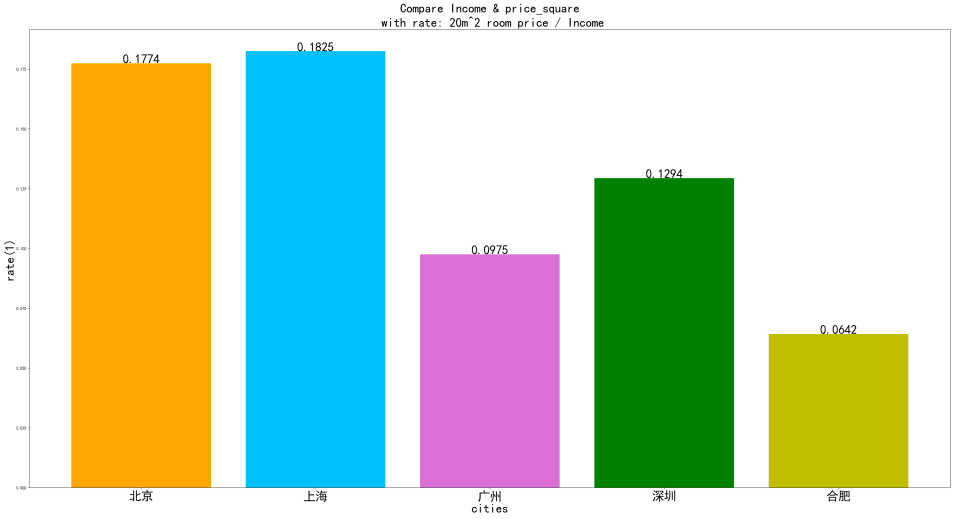

平均工资更能反映：北京上海差不多，其余三个明显低于上海北京，依旧合肥最低。

Q7： 拓展 - 可支配收入 & 单位面积租金分布

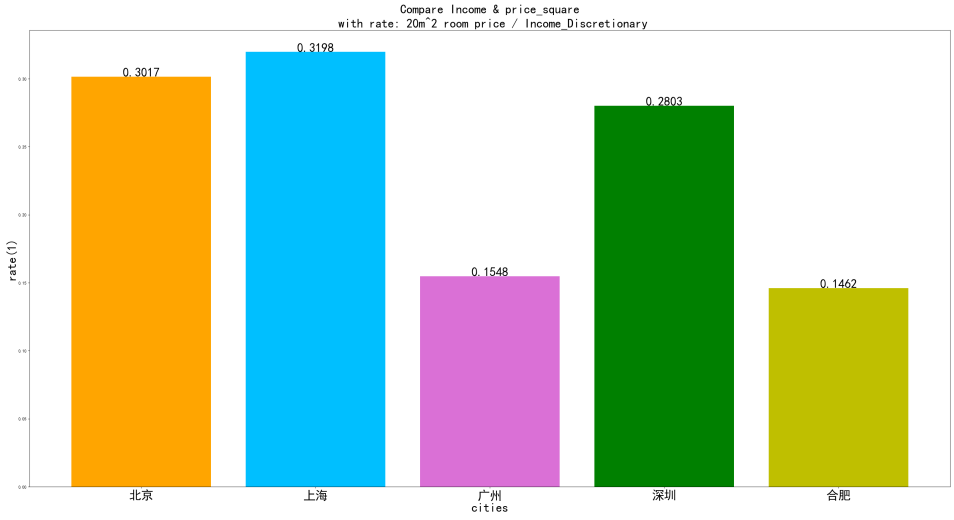

这里就看出来问题了：广州降到了合肥的水准！说明在可支配收入中房租占比广州很小，说明房租压力不是很大。

Q8： 拓展 - 租房人口比例 & 常住非户籍人口比例

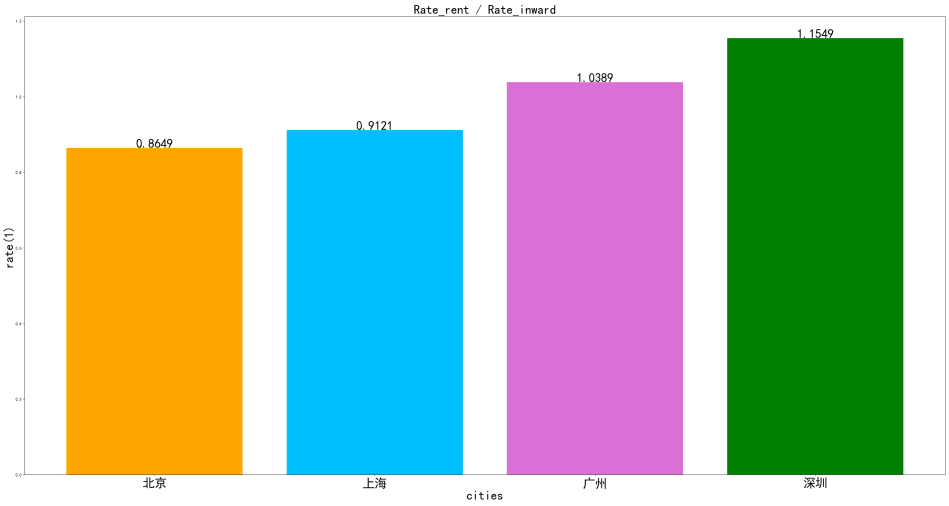

这是更有意思的一组数据。我们的租房人口占非户籍人口的比重，北京上海广州深圳依次增高，而北京上海小于1。这说明了入籍的难易程度：北京住了也难入籍，深圳你甚至租房也是本地户籍。所以可以看出深圳的招揽人才在户籍方面下了大功夫，而北京上海则对户籍严把关。

4. 遇到的问题 & 改进

1. 爬取数据：用板块方式取出的数据更可靠（综合排序页面爬取去重去脏数据后32000剩3000，地区爬取剩16000）
2. 取出换行和空格：数据要注意规整，尤其是像下图出现的数据缺省或非法。

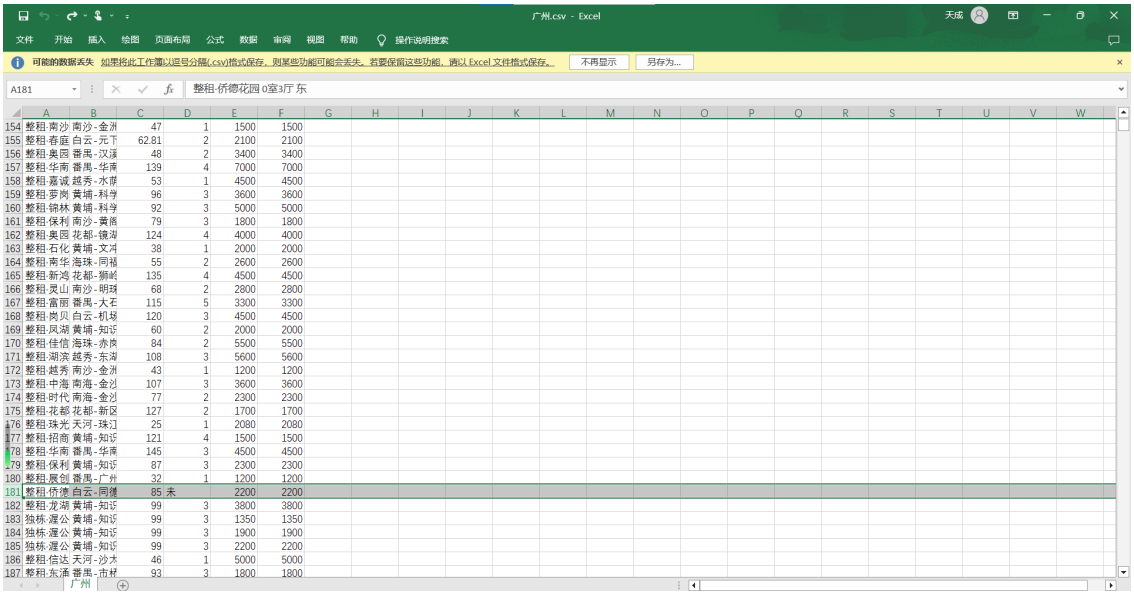

3. price的处理：记录最高和最低。有 - 则最低最高各一个，没有则都赋值该值。
4. 脏数据：

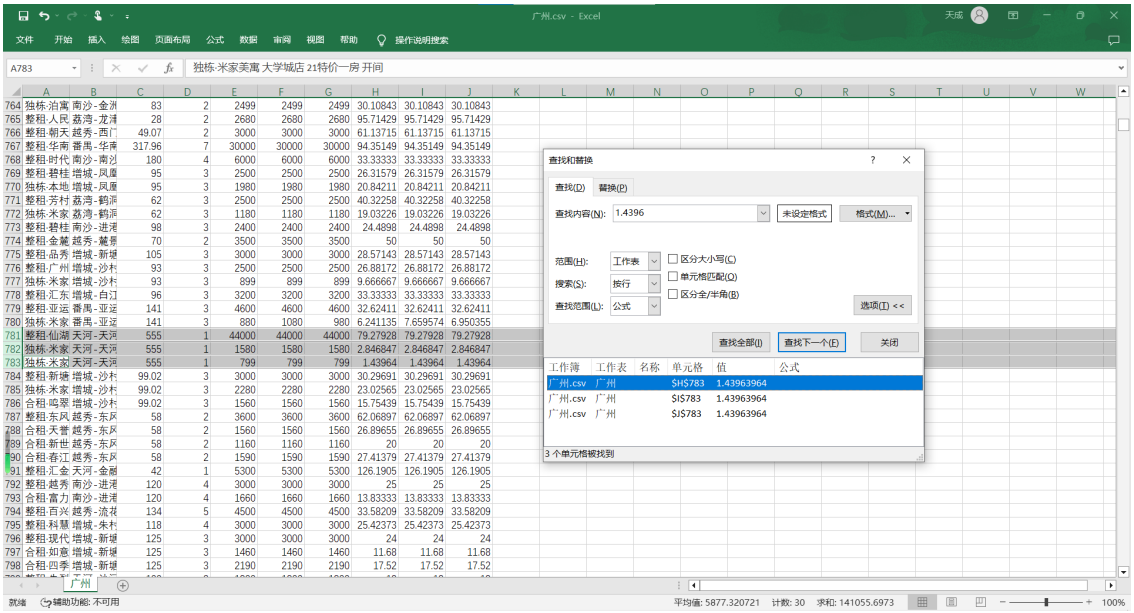
广州.csv - Excel
查找和替换
查找内容(N): 1.4396
3 个单元格被找到

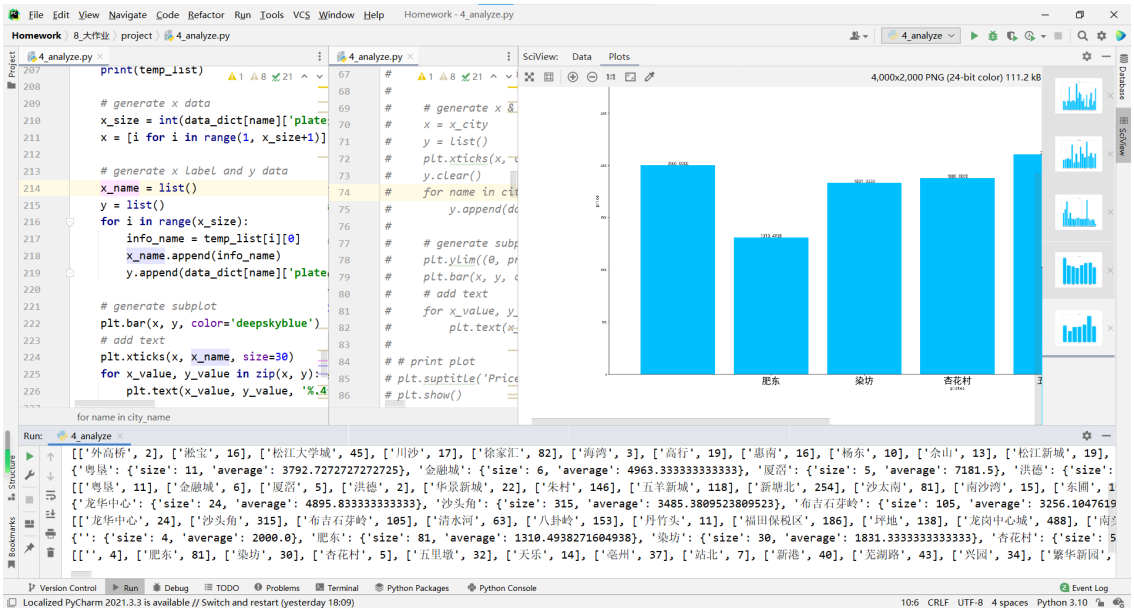
Homework - 4_analyze.py
4,000x2,000 PNG (24-bit color) 111.2 kB
肥东
染坊
杏花村